01 / 建模范围与验证协议

目标是预测Home Credit公开数据中的还款困难标签。全量主表307,511条、122个原始字段，TARGET=1占8.07%。该标签定义涉及未知X天、前Y期的迟付规则，不能等同于经确认的一年期违约或银行坏账。

分区	记录数	正例数	正例占比
fit	150,679	12,164	8.07%
tune	32,289	2,607	8.07%
calibration	16,144	1,303	8.07%
policy	16,145	1,303	8.07%
test	92,254	7,448	8.07%

外层70%开发、30%测试满足大纲划分要求。开发区再拆分为拟合、调参、校准和策略四部分。拟合区用于预处理、WOE、IV和筛选；调参区选择模型和树数；冻结后仅用拟合+调参区复训，再用独立校准区拟合概率映射、策略区选择阈值。

大纲工作项	本次实际完成范围
主表治理、特征工程、模型与解释	基于已上传主表实际运行，保留代码、模型、结果和测试。
多表信用历史及证券交易特征	六张历史明细未提供；资产波动、持仓集中度、担保比例等无法实测。
风险分层与业务价值	完成离线策略和明确假设下的情景测算，不是银行上线业绩。
监管、公平与上线验收	输出初步审计与上线门槛；不宣称通过法律合规或生产验收。

V2曾进行全样本EDA，因此这里是随机回溯留出评价，不是从未接触过的新外部数据。数据无完整申请日历信息，未声称完成时间外验证。来源：用户大纲第3页；outputs/phase2/split_manifest.json；官方scikit-learn防泄漏说明。

02 / 预处理与分层特征体系

维度	特征	业务解释与边界
外部信用信息	EXT_SOURCE_2	匿名外部标准化评分；来源算法未知，不将其解释成具体征信事件。
就业情况	EMPLOYMENT_YEARS	由就业天数换算；特殊值365243置缺失，不能直接视为失业。
申请与收入关系	CREDIT_INCOME_RATIO	本次申请金额/记录收入；不是总负债率，也不是经确认的月供收入比。
还款与商品金额代理	ANNUITY_CREDIT_RATIO等	年金/贷款、贷款/商品价格等比率；不擅自年化，需核实金额与期数口径。

预处理规则只在拟合数据学习

数值字段：缺失率低于10%用训练中位数填充；中高缺失保留NaN并加缺失指示。超过20个不同值的连续字段按训练0.5%和99.5%分位数盖帽，保留客户记录。类别字段：低缺失用训练众数，其他缺失单列；少于max(50,0.1%训练样本)的类别合并为Other。

就业特殊值365243共有55,374条，换算就业年数前置缺失并单独保留标记。收入为零或负值时不计算比率，不制造无穷值。ID和TARGET不进入预测；性别、出生年龄、婚姻、子女数量及两个额外外部评分不进入主模型。住房MODE/MEDI重复口径不与AVG同时保留。

编码方案实际实现

逻辑回归：数值等频分箱及类别分组后做训练内WOE。LightGBM：使用冻结词表的原生类别编码，不把类别编号视作数值顺序。另运行数值标准化+独热编码LR对照。未见类别映射到Other，未见WOE组回退为0。

完整处理参数：outputs/phase2/preprocessing_fit.csv。没有历史表支持的逾期占比、授信使用率、证券资产波动率等不生成假值；缺项登记见docs/requirements_matrix.csv。

03 / WOE、IV、共线性与评分卡

按训练IV≥0.005、非近零方差筛选，先按IV优先消除|相关系数|≥0.85的WOE特征，限制最多45项，再迭代剔除VIF>5或奇异项。最终选择41项进入WOE逻辑回归。特征选择日志同时记录未入选理由，不把IV相加当成独立信息增益。

入模特征（部分）	拟合IV	拟合VIF	LR系数
EXT_SOURCE_2	0.2806	1.20	−0.7941
EMPLOYMENT_YEARS	0.1045	1.58	−0.5372
OCCUPATION_TYPE	0.0799	1.35	−0.3307
ORGANIZATION_TYPE	0.0720	2.06	−0.5641
CREDIT_GOODS_RATIO	0.0681	1.17	−0.6402
REGION_RATING_CLIENT_W_CITY	0.0509	1.75	−0.3175
NAME_EDUCATION_TYPE	0.0509	1.21	−0.4474
NAME_INCOME_TYPE	0.0504	3.16	−0.0867
AMT_GOODS_PRICE	0.0465	3.89	−0.1001
ANNUITY_CREDIT_RATIO	0.0441	1.38	−0.6999
PHONE_CHANGE_YEARS	0.0392	1.09	−0.3553
AMT_CREDIT	0.0376	3.82	−0.1028

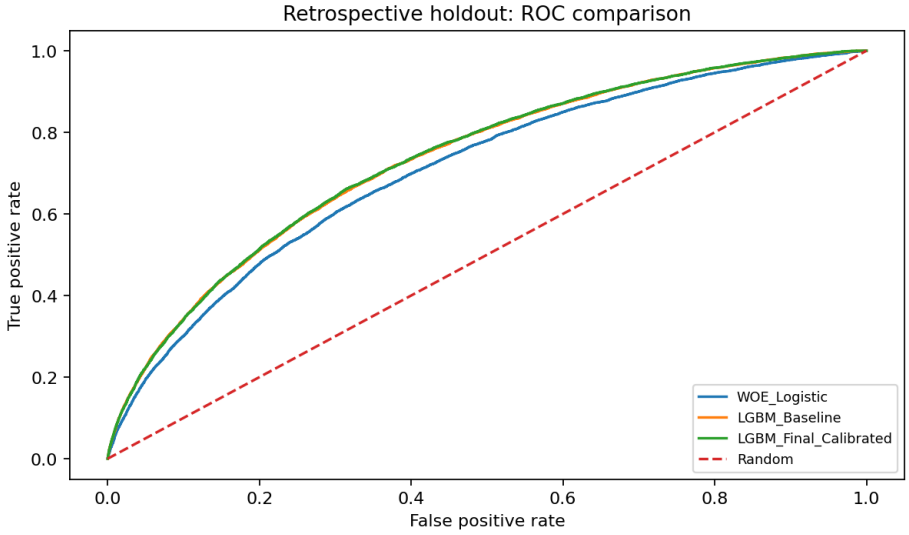
选定特征集合冻结后，在拟合+调参区重新学习变换和模型系数。WOE负值表示坏样本更集中，因此LR通常预期系数为负；本次有8项为正，已在系数表标记复核。该符号只描述模型条件关系，不作为因果结论。

额外导出可复核的LR分箱分值：600分对应好坏比50:1、PDO=20，分箱分值=−20/ln(2)×系数×WOE。该标尺仅用于演示，不是机构认证评分，且与最终LightGBM模型应区分。

证据：feature_screening.csv、vif_selected_fit.csv、woe_bins_fit.csv、woe_bins_refit.csv、logistic_coefficients.csv、logistic_scorecard.csv。各WOE表包含可读分箱边界。

04 / 基线模型实际测试结果

模型	AUC	KS	Gini	AP	Brier
WOE逻辑回归	0.7072	0.3047	0.4145	0.1847	0.07055
LightGBM基线	0.7326	0.3417	0.4651	0.2144	0.06925
优化模型（已校准）	0.7336	0.3470	0.4671	0.2143	0.06926



测试集92,254条；模型和阈值选择均不使用本轮测试标签。

逻辑回归基线AUC为0.7072；LightGBM基线为0.7326。最终优化版本AUC为0.7336、KS为0.3470。指标来自实际运行，不使用此前简历模板中的0.78、15%或20个百分点等预设数字。

模型	口径	阈值	精确率	召回率	FP	FN
WOE逻辑回归	fixed_0.5	0.5000	0.00%	0.00%	1	7,448
WOE逻辑回归	policy_KS	0.0854	14.52%	62.77%	27,520	2,773
优化模型（已校准）	fixed_0.5	0.5000	50.63%	1.07%	78	7,368
优化模型（已校准）	policy_KS	0.0881	16.47%	60.92%	23,007	2,911

policy_KS阈值在独立策略集选择；它只是分类诊断阈值，不等同于三档策略的两个边界。对约8%的少数类，0.5阈值召回很低，不能用约92%的准确率夸大模型效果。

05 / 编码对照、可复现与交接

实验方法	验证AUC	P@0.5	R@0.5	Brier
woe	0.7090	0.00%	0.00%	0.0704
woe_balanced	0.7089	14.08%	66.09%	0.2180
woe_smote	0.7078	28.70%	13.92%	0.0933
numeric_scaled_plus_one_hot	0.7130	30.00%	0.12%	0.0701

表中各实验只在拟合区训练、调参区比较。类别加权和SMOTE均改变类别先验，0.5阈值下召回可能提高，但未带来一致的AUC/Brier改善。SMOTE仅用于WOE数值空间的LR诊断，不把合成点解释成真实客户，也不在划分前对全量数据采样。

维度	WOE逻辑回归	LightGBM
关系表达	加性、分箱效应，便于检查系数	可捕捉非线性及变量组合
缺失处理	冻结缺失组或插补后编码	原生缺失分支及显式缺失指示
解释与复杂度	系数/分箱分值易审计	需SHAP及分组检查，不代表因果
适用边界	可解释基准，分箱需稳定性审查	离线预测能力更高，须加强治理

模型预处理和拟合均可复现：运行python -m credit_risk.pipeline，再运行python -m credit_risk.reporting生成PDF。项目记录随机种子42、原始文件SHA-256、分区样本量、包版本、模型参数与完整验证指标。

实际运行环境Python 3.13.5；原始数据SHA-256前缀为52e96b895b1112e1。models/model_bundle.joblib保存冻结预处理、WOE、基线模型、最终模型和校准器。只加载可信的模型文件，不能执行来源未知的joblib。

方法来源：scikit-learn Common pitfalls、LightGBM LGBMClassifier/Parameters、imbalanced-learn Common pitfalls。完整链接与检索日期见docs/references.md。